סיכום עבודת ה Pipeline והמודל: Olist marketplace

העבודה הנוכחית התמקדה בבניית Pipeline מלא ו-leakage-safe עבור נתוני Olist marketplace, מהטבלאות הגולמיות, דרך טיפול באתגרי איכות הנתונים, ועד להערכת מודל חיזוי וחישוב ה-lift מול ה Benchmark הקפוא.

1. שלבים חיוניים ב Pipeline וההחלטות שנתקבלו:

א. ערכים חסרים: פרופיילינג, סיווג המנגנון ואסטרטגיית אימפוטציה

פרופיילינג וסיווג: נערך ניתוח של הערכים החסרים, שהצביע על כך שבתכונות נומריות כמו ,product_weight_g product_length_cm, product_height_cm, ו-product_width_cm, יש רק ערך חסר בודד בכל אחת מהן (פחות מ-0.001% מכלל התצפיות). חוסרים אלו סווגו כ-Missing Completely At Random (MCAR), בהתחשב בכמותם הזניחה והסבירות לטעות דגימה אקראית.

אסטרטגיית אימפוטציה: ההחלטה הייתה להשתמש ב-SimpleImputer(strategy="median") עבור תכונות נומריות אלו. ה median נבחר על פני הממוצע בשל עמידותו הגבוהה יותר לחריגים, והוא עוזר לשמר את התפלגות הנתונים כאשר ערכים קיצוניים קיימים. עבור תכונות קטגוריות חסרות (כמו product_category_name שכבר טופלה בהסרת שורות בשל חשיבותה), האסטרטגיה המקובלת היא SimpleImputer(strategy="constant", fill_value="missing") יחד עם OneHotEncoder.

ב. חריגים: זיהוי והחלטה מנומקת (סטטיסטית ועסקית)

זיהוי: באמצעות נתונים תיאוריים של תכונות נומריות כמו price, freight_value, product_photos_qty, ומידות המוצר, זוהו ערכים מקסימליים גבוהים, המעידים על קיום חריגים פוטנציאליים.

החלטה: למרות קיום החריגים, ההחלטה הייתה לא להסיר או לקטום אותם באופן אגרסיבי בשלב זה. הנימוק העסקי הוא שנתוני המסחר האלקטרוני מכילים מוצרים בעלי טווח רחב של מחירים, מידות ומשקלים. הסרת מוצרים יקרים או גדולים עלולה להביא לאובדן מידע עסקי לגיטימי וחשוב. הנימוק הסטטיסטי הוא שהסקיילרים השונים (StandardScaler ו-RobustScaler) מספקים דרכים לטפל בהשפעתם של חריגים על המודל מבלי להשליך מידע. יתרה מכך, RobustScaler תוכנן במיוחד להיות עמיד לחריגים.

ג. סקיילינג וקידוד (Encoding) בהתאם למודל ולקרדינליות

מודל: נבחר מודל LogisticRegression, הדורש סקייל של התכונות הנומריות.

סקיילרים: נבחנו והושוו StandardScaler (משתמש בממוצע וסטיית תקן) ו-RobustScaler (משתמש ב median וטווח בין-רבעוני – IQR). RobustScaler הוכח כיעיל יותר במידה מועטה במערך הנתונים שלנו, עם ROC AUC של 0.6006 לעומת 0.6005 של StandardScaler.

קידוד קטגוריות: עבור התכונה הקטגורית product_category_name (שנמצאה כבעלת קרדינליות גבוהה יחסית), שימש OneHotEncoder. קידוד זה מתאים למודלים לינאריים ומונע מהמודל להניח יחס סדר בין הקטגוריות.

Columntransformer: שילוב הסקיילרים והמקודדים ל Pipeline אחד באמצעות ColumnTransformer איפשר טיפול מקביל בתכונות הנומריות והקטגוריות בצורה מסודרת ו-leakage-safe.

ד. חוסר איזון ובחירת מטריקה: המחלקה הנדירה כאחת מכל שש ביקורות היא זו שחשובה

האתגר: אחוז הביקורות השליליות (המחלקה הנדירה) עומד על כ-16% בלבד. חוסר איזון זה דורש טיפול מיוחד כדי שהמודל לא יתעלם ממחלקת המיעוט.

אסטרטגיה: נבחרה אסטרטגיית class_weight='balanced' במודל LogisticRegression. אסטרטגיה זו מקצה משקלים הפוכים לתדירות המחלקות, ומעניקה חשיבות יתרה לביקורות השליליות (מחלקת המיעוט) במהלך אימון המודל.

בחירת מטריקה: מדד ה-ROC AUC נבחר כמדד הביצועים העיקרי. מדד ה-Accuracy נדחה מכיוון שהוא מטעה במערכי נתונים לא מאוזנים. מודל יכול להשיג דיוק גבוה (למשל, 84% במקרה שלנו) על ידי חיזוי קבוע של מחלקת הרוב, ובכך להתעלם לחלוטין ממחלקת המיעוט, שהיא דווקא המטרה העסקית שלנו (זיהוי ביקורות שליליות). ROC AUC, לעומת זאת, מעריך את יכולת המודל להבחין בין המחלקות בכל ספי החיתוך האפשריים, ומספק תמונה אמינה יותר של ביצועי המודל במקרה של חוסר איזון.

2. מדידת ה-Lift מול ה-Benchmark הקפוא

המודל הסופי שלנו (עם RobustScaler ו-'class_weight='balanced') הוערך מול ה-benchmark הקפוא, תוך שמירה על פרוטוקול הערכה זהה (Cross-Validation ו-ROC AUC).

ROC AUC – Benchmark: 0.5586

ROC AUC – My Model : 0.5992

Lift: 0.0406

מסקנה: הושג שיפור משמעותי של 0.0406 נקודות ROC AUC ביחס ל Benchmark. ליפט חיובי זה מאשר כי ההחלטות שנתקבלו בכל שלבי ה Pipeline – טיפול מושכל בערכים חסרים, בחירת סקיילר עמיד לחריגים, וטיפול מותאם בחוסר איזון בין המחלקות – תרמו באופן אפקטיבי לשיפור יכולת המודל לזהות ביקורות שליליות.